

UNIVERSIDAD  
PANAMERICANA

# Machine Learning

(<https://leonpalafox.github.io/mlclase/>)

Leon F. Palafox PhD

# Noticias



## The Arrival of Artificially Intelligent Beer

**WRITTEN BY ALASDAIR ALLAN**

29 August 2016 // 02:37 PM CET

# Recap – Regresion Lineal

- Imagine you want to sell you car:

- How much do you ask for it:

- Mileage
- Year
- Color
- Options
- Condition



# Valores de autos?

Model	Year	Brand	Price	Options	Condition	Mileage
Corvette	1961	Chevrolet	100K	Standard	As New	100,000
Corvette	1961	Chevrolet	10K	Standard	Rust	100,000
Corvette	1961	Chevrolet	120K	Standard	Used	20,000

Price = Year + Options + Condition + Mileage

This doesn't work

Price = A\*Year+ B\*Options + C\*Condition+ D\*Mileage



# Forma Matricial

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ x_{21} & \cdots & x_{2p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix},$$


$$\boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix}$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta}$$

# Ingenieria de Features



By adding an extra squared factor,  
we got a perfect fit




# Ingeniería de Features

- <https://eng.uber.com/cota/>
- <https://medium.com/netflix-techblog/distributed-time-travel-for-feature-generation-389ccdd3907>

# Expansión de espacios

- Al poner mas features, nos movemos a dimensiones superiores.





# Problema de Optimización

- Optimize:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta}$$

- Score:

$$X\boldsymbol{\beta} - y$$

$$(X\boldsymbol{\beta} - y)^2$$

$$\frac{1}{2}(X\boldsymbol{\beta} - y)^2$$

This is considered  
a cost!

# Usando algebra matricial

$$\begin{aligned}\frac{1}{2}(X\beta - y)^2 &= \frac{1}{2}(X\beta - y)^T(X\beta - y) \\ &= J(\beta)\end{aligned}$$

$$\nabla_{\beta} J(\beta) = 0$$

# Usando algebra matricial

$$\nabla_{\beta} J(\beta) = X^T X \beta - X^T y = 0$$

$$X^T X \beta = X^T y$$

$$\beta = (X^T X)^{-1} X^T y$$

# Gradient descent

$$h_{\beta}(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

$$J(\beta) = \frac{1}{2} \sum_{i=1}^m (h_{\beta}(x^{(i)}) - y^{(i)})^2$$

$$\beta_{j+1} = \beta_j - \alpha \frac{\delta}{\delta \beta_j} J(\beta)$$


# Gradient descent

$$\beta_{j+1} = \beta_j - \alpha(y - h_{\beta}(x^{(i)}))x_j^{(i)}$$

# Cual es la diferencia

- Grandes cantidades de datos:
  - Gradiente descente es el rey!
  - Algebra Matricial es terrible (por que?).
- Pequeños datos
  - Algebra Matricial es lo mejor.
- En práctica se usa gradient descendente por que las bases de datos se hacen grandes de manera muy rapida.

# Como controlamos el problema de ayer



# Regularizacion

- Trata de mantener los valores de los pesos bajos (por que?).


$$J(\beta) = \frac{1}{2}(y - h_{\beta}(x^{(i)}))^2 + \lambda \|\beta\|$$

$$J(\beta) = \frac{1}{2}(y - h_{\beta}(x^{(i)}))^2 + \alpha \|\beta\|$$

- Esto se denomina Ridge Regression



# Un ejemplo de uso




<https://www.youtube.com/watch?v=AR3hY9iB5-I>

# Nuestro super martillo– Support Vector Machines


- SVMs son la mejor herramienta para hacer clasificacion que necesita pocas variaciones.
  - Es razonablemente facil de usar
  - Tiene pocos parametros para optimizar
  - Funciona increiblemente bien.
  - Es rapido



# Support Vector Machines (SVMs)



# SVM Introduction




# Kernels


- Utilizar lineas es impractico por que no necesariamente es la major solución.
- Usamos el concepto del Kernel (Distancia)
  - Diferentes Kernels nos permiten usar diferentes espacios
  - Los mas communes:
    - Linear
    - Polynomial (expanded powers) (power of polynomial)
    - RBF (Gaussian Kernel) (“variance”)

# Kernels


SVC with linear kernel




LinearSVC (linear kernel)



SVC with RBF kernel



SVC with polynomial (degree 3) kernel




<http://scikit-learn.org/stable/modules/svm.html#svm-kernels>

# Support Vector Machines (SVMs)

- Froman parte de la familia de los métodos de Kernels
- Estos métodos son muy versátiles
  - Mucha investigación se hace alrededor de cual es el mayor Kernel.
  - Es una lata de gusanos
  - La panacea es tener Kernels que se autodefinan

# Parameter C



$$\min_{\gamma, w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i$$

$$\text{s.t. } y^{(i)}(w^T x^{(i)} + b) \geq 1 - \xi_i, \quad i = 1, \dots, m$$

$$\xi_i \geq 0, \quad i = 1, \dots, m.$$